

Aplicação de Métodos de Machine Learning ao Estudo do Canal de Controle do Decaimento $B^0 \rightarrow K^{*0}(892) \mu^+ \mu^-$

Modelo Padrão da Física de Partículas

three generations of matter (fermions)			interactions / force carriers (bosons)	
I	II	III		
mass charge spin $\approx 2.16 \text{ MeV}/c^2$ $\frac{2}{3}$ $\frac{1}{2}$ u up	$\approx 1.273 \text{ GeV}/c^2$ $\frac{2}{3}$ $\frac{1}{2}$ c charm	$\approx 172.57 \text{ GeV}/c^2$ $\frac{2}{3}$ $\frac{1}{2}$ t top	0 0 1 g gluon	$\approx 125.2 \text{ GeV}/c^2$ 0 0 0 H higgs
QUARKS $\approx 4.7 \text{ MeV}/c^2$ $-\frac{1}{3}$ $\frac{1}{2}$ d down	$\approx 93.5 \text{ MeV}/c^2$ $-\frac{1}{3}$ $\frac{1}{2}$ s strange	$\approx 4.183 \text{ GeV}/c^2$ $-\frac{1}{3}$ $\frac{1}{2}$ b bottom	0 0 1 γ photon	
LEPTONS $\approx 0.511 \text{ MeV}/c^2$ -1 $\frac{1}{2}$ e electron	$\approx 105.66 \text{ MeV}/c^2$ -1 $\frac{1}{2}$ μ muon	$\approx 1.77693 \text{ GeV}/c^2$ -1 $\frac{1}{2}$ τ tau	$\approx 91.188 \text{ GeV}/c^2$ 0 1 Z Z boson	
$< 0.8 \text{ eV}/c^2$ 0 $\frac{1}{2}$ ν_e electron neutrino	$< 0.17 \text{ MeV}/c^2$ 0 $\frac{1}{2}$ ν_μ muon neutrino	$< 18.2 \text{ MeV}/c^2$ 0 $\frac{1}{2}$ ν_τ tau neutrino	$\approx 80.3692 \text{ GeV}/c^2$ ± 1 1 W W boson	SCALAR BOSONS
			GAUGE BOSONS VECTOR BOSONS	

- O Modelo Padrão é **atualmente a melhor teoria** que descreve tanto as partículas elementares quanto suas interações.

$$SU(3)_c \times SU(2)_L \times U(1)_Y$$

- Descoberta do **bóson de Higgs**, a partícula responsável pela geração de massa.
- Este modelo também apresenta algumas **limitações**, tais como:
 - Não incorporação da gravitação.
 - Assimetria entre matéria e antimatéria (violação de CP).
 - O problema da hierarquia de massas.
 - Oscilações de sabor dos neutrinos.
 - ...

Interação Eletrofraca

Nesta análise, estamos muito interessados no papel da força fraca, que possui dois tipos de processos chamados de **interações de corrente carregada** entre quarks e o bóson $W^\pm W^\pm$, cuja Lagrangiana é dada por:

$$\mathcal{L}_{W^\pm} = \frac{g}{\sqrt{2}} \left[\overline{U}_L^i \gamma^\mu (V_{\text{CKM}})_{ij} D_L^j W_\mu^+ + \overline{D}_L^j \gamma^\mu (V_{\text{CKM}})_{ij} U_L^i W_\mu^- \right],$$

Nessa Lagrangiana, g é a constante de acoplamento eletrofraco, e V_{CKM} é a matriz que representa os **constantes de acoplamento entre os quarks**.

$$V = \begin{pmatrix} |V_{ud}| & |V_{us}| & |V_{ub}| \\ |V_{cd}| & |V_{cs}| & |V_{cb}| \\ |V_{td}| & |V_{ts}| & |V_{tb}| \end{pmatrix} = \begin{pmatrix} 0.97370 \pm 0.00014 & 0.2245 \pm 0.0008 & 0.00382 \pm 0.00024 \\ 0.221 \pm 0.004 & 0.987 \pm 0.011 & 0.0410 \pm 0.0014 \\ 0.0080 \pm 0.0003 & 0.0388 \pm 0.0011 & 1.013 \pm 0.039 \end{pmatrix}.$$

Os elementos da matriz CKM foram medidos experimentalmente, e observou-se que essa matriz é “quase” diagonal. Isso significa que as **transições de sabor entre quarks de uma mesma família são mais prováveis** do que aquelas entre quarks de famílias diferentes.

Interação Eletrofraca

Também temos as **interações de corrente neutra**, que são descritas pelas seguintes Lagrangianas:

$$\mathcal{L}_\gamma = eA_\mu \left(-\frac{2}{3}\bar{U}\gamma^\mu U + \frac{1}{3}\bar{D}\gamma^\mu D \right) \quad \mathcal{L}_{Z^0} = \frac{g}{\cos\theta_w} Z_\mu \left[\bar{U}\gamma^\mu \left(\frac{P_L}{2} - \frac{2\sin^2\theta_w}{3} \right) U + \bar{D}\gamma^\mu \left(\frac{\sin^2\theta_w}{3} - \frac{P_L}{2} \right) D \right].$$

Onde A_μ representa o campo do fóton. Dadas essas Lagrangianas, observamos que tais interações não podem ocorrer em nível de árvore no Modelo Padrão, **pois são processos extremamente suprimidos** que só podem ocorrer por meio de diagramas de dois loops.




Diagrama de Feynman do tipo pinguim [1]




Diagrama de Feynman do tipo caixa [2]

Esses tipos de processos são extremamente raros devido ao fato de serem do tipo **FCNC** e envolverem transições entre quarks de diferentes gerações, conforme descrito pela **matriz CKM**.

Busca por Nova Física

Para o estudo de Nova Física, processos como $b \rightarrow s$ e $b \rightarrow d$ são extremamente valiosos, pois qualquer desvio é altamente sensível, o que pode levar à descoberta de novas partículas, tais como:




Diagrama de Feynman de LQ [3]





Diagrama de Feynman de Z' [4]

Leptoquarks (LQ) e o bóson Z' poderiam permitir a ocorrência de processos do tipo FCNC (correntes neutras de sabor) já no nível de árvore. Embora nenhuma dessas partículas tenha sido descoberta até o momento, sua detecção representaria uma **evidência direta** de nova física.

Algumas previsões do Modelo Padrão estão apresentando **discrepâncias em relação aos resultados experimentais**, como nas taxas de decaimento e frações de ramificação. Esses desvios fornecem **evidências indiretas**, sugerindo que há espaço para a exploração de nova física além do Modelo Padrão.


Processos de Background



Alguns processos distintos podem apresentar a **mesma assinatura final no detector**, contribuindo para a contaminação do sinal verdadeiro. Um exemplo é o decaimento $B^0 \rightarrow K^{*0}(892) (J/\Psi) \mu^+ \mu^-$ cuja topologia final é idêntica à de outros processos do tipo $B^0 \rightarrow K^{*0}(892) \mu^+ \mu^-$. Esses eventos podem **induzir falsos positivos ou negativos na classificação**, afetando diretamente a pureza da amostra.

Portanto, para uma análise realmente precisa e confiável, é essencial identificar, isolar e tratar corretamente essas contribuições ressonantes, garantindo que o treinamento dos modelos não absorva viés e que os resultados refletem apenas os eventos de interesse.

LHC e o Detector CMS



Experimento CMS

CMS DETECTOR

Total weight : 14,000 tonnes
 Overall diameter : 15.0 m
 Overall length : 28.7 m
 Magnetic field : 3.8 T

STEEL RETURN YOKE
 12,500 tonnes

SILICON TRACKERS
 Pixel ($100 \times 150 \mu\text{m}$) $\sim 1\text{m}^2 \sim 66\text{M}$ channels
 Microstrips ($80 \times 180 \mu\text{m}$) $\sim 200\text{m}^2 \sim 9.6\text{M}$ channels

SUPERCONDUCTING SOLENOID
 Niobium titanium coil carrying $\sim 18,000\text{A}$


MUON CHAMBERS
 Barrel: 250 Drift Tube, 480 Resistive Plate Chambers
 Endcaps: 540 Cathode Strip, 576 Resistive Plate Chambers

PRESHOWER
 Silicon strips $\sim 16\text{m}^2 \sim 137,000$ channels


FORWARD CALORIMETER
 Steel + Quartz fibres $\sim 2,000$ Channels

CRYSTAL
 ELECTROMAGNETIC
 CALORIMETER (ECAL)
 $\sim 76,000$ scintillating PbWO_4 crystals

HADRON CALORIMETER (HCAL)
 Brass + Plastic scintillator $\sim 7,000$ channels



Formato dos Dados e Geração



Pré-Processamento dos Dados

Este notebook tem como finalidade **preparar e formatar dados brutos** de física de partículas, provenientes de arquivos ROOT, para que possam ser utilizados em análises de Machine Learning.

Ele foca em:

- Extrair variáveis relevantes.
- Calcular novas variáveis (Feature Engineering).
- Filtrar eventos específicos (Sinal vs. Fundo).
- Reestruturar os dados em um formato mais amigável.

Os dados brutos são fornecidos em dois arquivos `.root`, cada um contendo uma estrutura de dados `TTree` chamada `"ntuple"`:


- **`reco_ntuple*_LMNR_1.root` (Monte Carlo - MC):**
 - Dados de simulação que representam o **Sinal** (eventos de interesse).
 - Quantidade de Eventos: 2772
- **`ntuple*_flat_LMNR_PostRefitMomenta_test_2022F_skimSoftMu_1.root` (Dados Experimentais - ED):**
 - Dados reais coletados de um detector, usados aqui para representar o **Fundo** (eventos não-sinal).
 - Quantidade de Eventos: 57695

Pré-Processamento dos Dados

Os dados brutos **NÃO ESTÃO** prontos para o ML sem estas etapas.


- **Cálculo de Variáveis de Significância (...s):**
 - Variáveis como **bLBSs** são criadas dividindo a medida pelo seu erro (**bLBS** / **bLBSE**). Isso as normaliza pela incerteza, tornando-as mais robustas.
- **Determinação do "Sabor" (flavour_tag):**
 - A função **flavour_tag** identifica o sabor mais provável da partícula (K^* ou K^* Bar) comparando as massas reconstruídas com a massa de ressonância do K^* (892).
 - Isso é vital para usar as massas corretas (**bTMass**, **kstTMass**) para o sabor identificado.
- **Seleção de leadingPt e trailingPt:**
 - Identifica a partícula com maior e menor momento transversal, fornecendo informações ordenadas ao modelo.
- **Filtragem de Eventos (Cortes):**
 - **Classificação Sinal/Fundo por Massa:** Eventos de sinal (MC) são selecionados dentro de uma janela de massa específica, enquanto eventos de fundo (dados experimentais) são selecionados nas "regiões laterais" (fora da janela de sinal).
 - **Truth Matching (Apenas MC):** Para o Monte Carlo, um filtro **tmatch** garante que apenas os eventos onde as partículas reconstruídas correspondem às partículas simuladas sejam considerados, garantindo a pureza do sinal.
 - **Filtro Final:** Somente eventos que satisfazem todas as condições de **truth matching** (para MC) e as classificações de sinal/fundo são salvos.

Variáveis utilizadas





Nome da Variável	Descrição
kstarmass	Massa do K^{*0} , após a marcação (tagging)
bVtxCL	Probabilidade χ^2 do vértice secundário
bLS / bLSE	Significância da distância transversal entre o vértice secundário e o ponto de interação (beamspot)
bCosAlphaBS	Cosseno do ângulo de apontamento entre o momento do B^0 e o vetor de distância do beamspot até o vértice do B^0 , no plano transversal
bDCABS / bDCABSE	Significância do parâmetro de impacto transversal do B^0 em relação ao beamspot
kstTrkmDCABS / kstTrkmDCABSE	Significância do parâmetro de impacto transversal da partícula com carga negativa (track ⁻) em relação ao beamspot
kstTrkpDCABS / kstTrkpDCABSE	Significância do parâmetro de impacto transversal da partícula com carga positiva (track ⁺) em relação ao beamspot

Estratégia de Análise









- Estratégia de análise foi a mesma adotada no Analysis note, na medida do possível:
 - Não foi feito nenhum tipo de corte cinemático pois a estatística era muito baixa
 - Para treinar a BDT a ideia foi fazer o fit na região de massa do méson B usando a simulação e selecionando somente a região de $MB_{\text{PDG}} \pm 3\sigma$.
 - Para Background foi utilizado a região de $MB_{\text{PDG}} \pm 3\sigma$ a $MB_{\text{PDG}} \pm 7\sigma$.

Análise preliminar dos dados



Overlay



Aplicação de ML

Alta Performance e Robustez:

- **BDT (Boosted Decision Trees)** são algoritmos poderosos, com o **XGBoost** sendo uma implementação líder nas análises.
- Excelentes para uma vasta gama de problemas de **classificação e regressão**, muitas vezes superando outros modelos tabulares.

Eficiência e Velocidade:

- **Otimizado para velocidade e uso de recursos**, o XGBoost é notavelmente rápido e escalável, suportando paralelização (usando múltiplos núcleos da CPU).
- Lida bem com grandes conjuntos de dados.


Tratamento de Dados:

- **Não requer normalização ou padronização de features:** Funciona bem com dados em diferentes escalas.
- **Robusto a outliers:** Menos sensível a valores extremos nas features.
- **Lida automaticamente com valores ausentes (missing values).**

Menos Ajuste de Hiperparâmetros:

- Comparado a redes neurais profundas, geralmente exige um **número menor de hiperparâmetros** para serem otimizados, e são menos sensíveis a pequenas variações neles.

Resultados



- O melhor conjunto de hiperparâmetros foi usado em uma **validação cruzada com 5 folds**.
- Para cada fold, foi plotada a **curva ROC** com a AUC individual.
- Também foi computada a **média das curvas ROC** dos folds.

Separação dos conjuntos de treino, validação e teste

- O conjunto total foi dividido da seguinte forma:
 - **80% treino/validação**, subdividido depois em:
 - 64% para **treinamento**.
 - 16% para **validação**.
 - **20% restante para teste final**.



Definição inicial do modelo

- Utilizou-se o **XGBClassifier**, um modelo de árvores de decisão *boosted*:
 - **Boosting** combina múltiplas árvores fracas (com baixa profundidade) para formar um modelo forte.
 - Foi usada a métrica **auc** para avaliar o desempenho durante o treino.

Otimização dos hiperparâmetros – **GridSearchCV**


- Um grid de hiperparâmetros foi definido:
 - **n_estimators**, **max_depth**, **learning_rate**, **subsample**, **colsample_bytree**.
- A busca foi feita com validação cruzada estratificada (**cv=5**).
- Métrica usada: **ROC AUC**.
- O melhor conjunto de parâmetros foi selecionado automaticamente com base nos folds de validação.

Resultados



A área sob a curva ROC (AUC-ROC) obtida para o conjunto de **validação** foi de **0.97**, enquanto para o conjunto de **teste** foi de **0.98**. Esses valores indicam que o classificador treinado com o XGBoost apresenta **excelente capacidade discriminativa** entre os eventos de sinal e fundo.

Resultados



A matriz de confusão obtida no conjunto de **teste** mostra um desempenho bastante satisfatório do classificador:



- O modelo identificou corretamente **433 eventos de sinal (VP)** e **11.509 eventos de fundo (VN)**.
- Cometeu **apenas 31 erros ao classificar eventos de fundo como sinal (FP)**, o que indica uma **baixa taxa de falsos positivos**, essencial para evitar contaminação do sinal por ruído de fundo.
- Por outro lado, houve **121 eventos de sinal classificados incorretamente como fundo (FN)**, o que representa uma **perda moderada de eficiência** na identificação do sinal.

A partir desses valores, é possível calcular algumas métricas relevantes:

- **Acurácia** = $(VP + VN) / \text{Total} = (433 + 11.509) / (433 + 11.509 + 31 + 121) \approx 98,7\%$
- **Eficiência (Recall)** para o sinal = $VP / (VP + FN) = 433 / (433 + 121) \approx 78,2\%$
- **Pureza (Precisão)** do sinal = $VP / (VP + FP) = 433 / (433 + 31) \approx 93,3\%$

Esses resultados indicam que o classificador tem **alta pureza** (baixa taxa de falsos positivos) e **boa eficiência**, sendo eficaz na separação entre eventos de sinal e fundo. A pequena quantidade de falsos negativos sugere que o modelo pode estar levemente conservador ao classificar sinais, priorizando reduzir falsos positivos — comportamento comum em situações em que se busca maior confiança na identificação do sinal.

Resultados



A distribuição da resposta do BDT para os eventos de **sinal** e **fundo** mostra uma clara separação entre as duas classes. A maioria dos eventos de sinal apresenta valores de *BDT score* próximos de **1**, enquanto os eventos de fundo concentram-se em torno de **0**. Essa separação é indicativa de que o modelo aprendeu de forma eficaz a distinguir entre os dois tipos de eventos com base nas variáveis de entrada.

Observou-se que algumas variáveis, como **kstTMass**, **bDCABs** e **kstTkmDCABs**, apresentaram **alta importância relativa**, sendo frequentemente utilizadas pelo modelo para discriminar entre sinal e fundo. Isso indica que essas variáveis contêm **informação relevante e não redundante** para a tarefa de classificação.

Conclusão

- Aplicamos técnicas de Machine Learning para estudar o canal de controle do decaimento $B^0 \rightarrow K^{*0}(892) J/\psi (\mu^+ \mu^-)$, um processo fundamental para validar métodos usados em buscas por Física além do Modelo Padrão.
- Modelos supervisionados foram treinados para identificar e separar sinais do decaimento em meio ao background, com foco em melhorar a eficiência e pureza da seleção de eventos.
- Os algoritmos demonstraram boa capacidade discriminante, com desempenho de 98% nas amostras de testes e excelentes métricas, como: Acurácia, precisão e etc...

Portanto, este trabalho será uma **base fundamental para minha dissertação de mestrado**, na qual pretendo realizar uma análise aprofundada não apenas deste canal de controle, mas também de **outros canais que podem interferir ou contribuir com o sinal** em regiões cinemáticas semelhantes.